

Deep Learning and Industrial Applications

Homework 4

Name: 江忻祐

Student ID: 113034552

1.

	MSE
window size =20 , step = 1	2.2830
window size = 10, step = 1	1.1131
window size = 5, step = 1	1.0612

窗口大小為 5 時，MSE 最低 1.0612，表現最佳，略優於 window size = 10 時的 MSE = 1.1131。window size 增加到 20 時，MSE 升高至 2.2830，表現較差。對於此數據和模型，使用較短的歷史數據進行預測效果最好，過長的 window size 可能引入了較舊的資訊，反而降低預測的準確度。

2.

(i)

將 Volume 納入輸入特徵後，模型能考慮交易量變化對股價的潛在影響，但模型的預測基本上是一條水平線，無法反映實際股價的趨勢，這代表模型幾乎沒有學習到任何有效的模式，Volume 的貢獻有限，可能因為未標準化 Volume。

(ii)

	MSE
['Open', 'High', 'Low', 'Close', Volume]	987.0007
['Open', 'High', 'Low', 'Close']	1.0612
['High', 'Low', 'Close']	1.3638
['Open', 'High', 'Close']	1.1144
['Open', 'High', 'Low',]	2.5436

經過多組特徵組合實驗，發現 ['Open', 'High', 'Low', 'Close'] 是預測股價高點最有效的特徵組合，包含每日開盤、收盤、最高與最低價，能全面呈現當日市場波動而不引入雜訊。雖然 Volume 是有潛力的特徵，但若未經標準化會對模型帶來反效果，不建議直接加入。

3.

模型未經標準化時，常出現無法學習價格變化的現象。這是因為 **Volume** 的數值遠大於價格特徵，使模型忽略其他關鍵訊息。加入 **StandardScaler** 進行特徵標準化後，所有輸入特徵被調整至相似的尺度範圍，有助於 **LSTM** 模型更有效學習各維度資訊。根據實驗結果，標準化後的模型在驗證集上 **MSE** 明顯下降。

4.

若 **window size** 大於 **step**，每個視窗之間會有重疊，對模型學習序列變化有幫助。如果 **window size** 小於 **step**，每次滑動間跳過太多資料，會降低模型的學習效果。在《**Deep Learning for Time Series Forecasting**》(Jason Brownlee) 中，建議使用 **window size $\geq$ step**。

5.

Jittering 是對原始時間序列在每個時間點上加入隨機噪聲，通常假設資料本身就帶有一定程度的量測誤差或干擾，透過加入小幅度的噪聲，讓模型見到更多變異後的序列，同時保留原序列的形狀。這種方法廣泛應用於感測器資料、金融資料等對極小變動敏感的時間序列模型中。

參考文獻：

Um, T. T., Pfister, F. M. J., Pichler, D., Endo, S., Lang, M., Hirche, S., Fietzek, U., & Kulić, D. (2020). Data augmentation of wearable sensor data for Parkinson's disease monitoring using convolutional neural networks. *Proceedings of the International Symposium on Wearable Computers*.

6.

(i)

卷積神經網路常以定長視窗輸入，每次推論可採用 **sliding window** 策略，固定步長從序列頭至尾切片，對每一片段預測，最後將重疊區域結果取平均平滑輸出。

(ii)

RNN、**LSTM** 等可處理變長序列，推論時將整條序列一次輸入，模型會自動根據時間步展開。若序列過長，可分為多個定長視窗，沿襲帶狀隱狀態傳播方式。

(iii)

Transformer 需固定輸入長度，若序列超出此長度可用 **sliding window attention** 或一次全局 + 多次局部策略對長序列分段，先計算局部自注意力，再以少量全局 **token** 進行信息融合。